Tutorium 10: Parallelprogrammierung mit MPI

Paul Brinkmeier

17. Januar 2023

Tutorium Programmierparadigmen am KIT

Heutiges Programm

Parallelprogrammierung

ProPa-Stoff zu Parallelprogrammierung:

- Grundlegende Begriffe
- Message Passing, wurde in OS *kurz* behandelt („message queues“)
- Shared Memory + Synchronisierung, wie in SWT1, OS, etc.
    - Mit ein paar Java-Details

Begriffe

Flynns Taxonomie

- SISD: Single Instruction, Single Data

  Ein Datum wird von einer Ausführungsarbeit bearbeitet
- SIMD: Single Instruction, Multiple Data

  Eine Ausführungseinheit bearbeitet mehrere Daten gleichzeitig
- MIMD: Multiple Instruction, Multiple Data

  $\approx$ Mehrere Ausführungseinheiten arbeiten gleichzeitig
- MISD: Multiple Instruction, Single Data

  $\approx$ Mehrere Ausführungseinheiten arbeiten gleichzeitig an einem Datum

Flynns Taxonomie

- SISD: Single Instruction, Single Data

  Ein Datum wird von einer Ausführungsarbeit bearbeitet
- SIMD: Single Instruction, Multiple Data

  Eine Ausführungseinheit bearbeitet mehrere Daten gleichzeitig
- MIMD: Multiple Instruction, Multiple Data

  $\approx$ Mehrere Ausführungseinheiten arbeiten gleichzeitig
- MISD: Multiple Instruction, Single Data

  $\approx$ Mehrere Ausführungseinheiten arbeiten gleichzeitig an einem Datum

Beispiele?

SISD

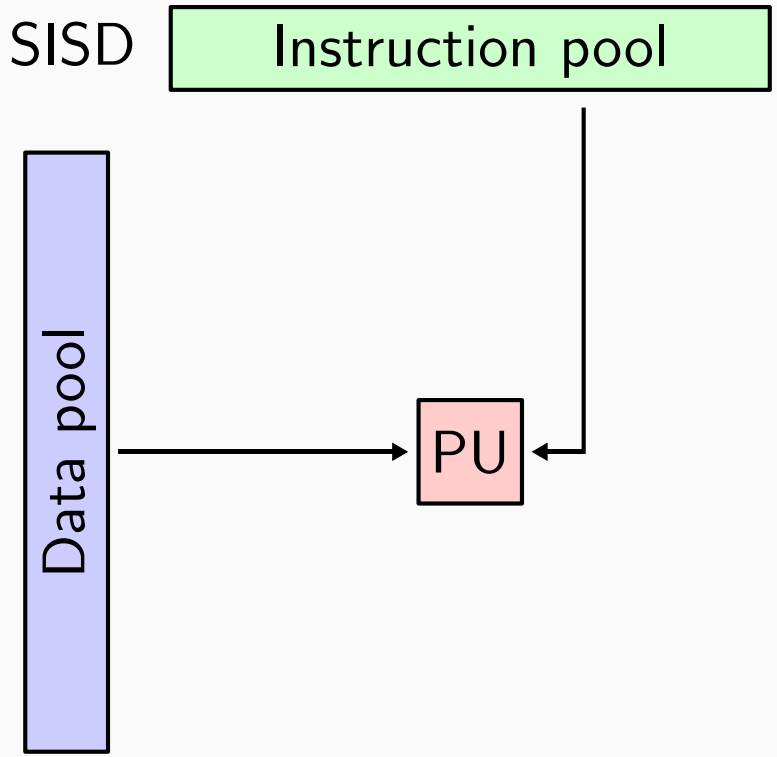

Single Instruction, Single Data

SIMD

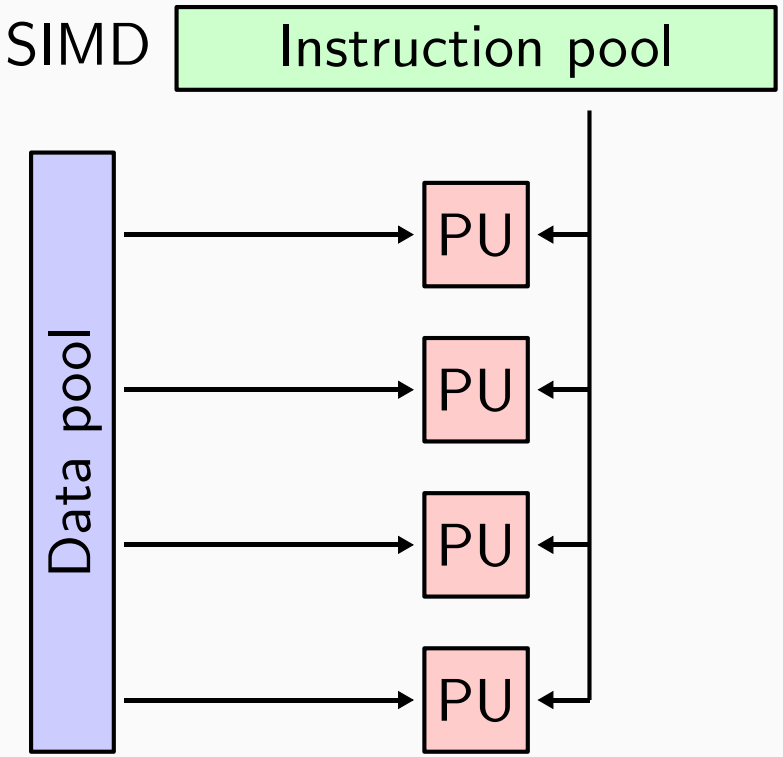

Single Instruction, Multiple Data

MIMD

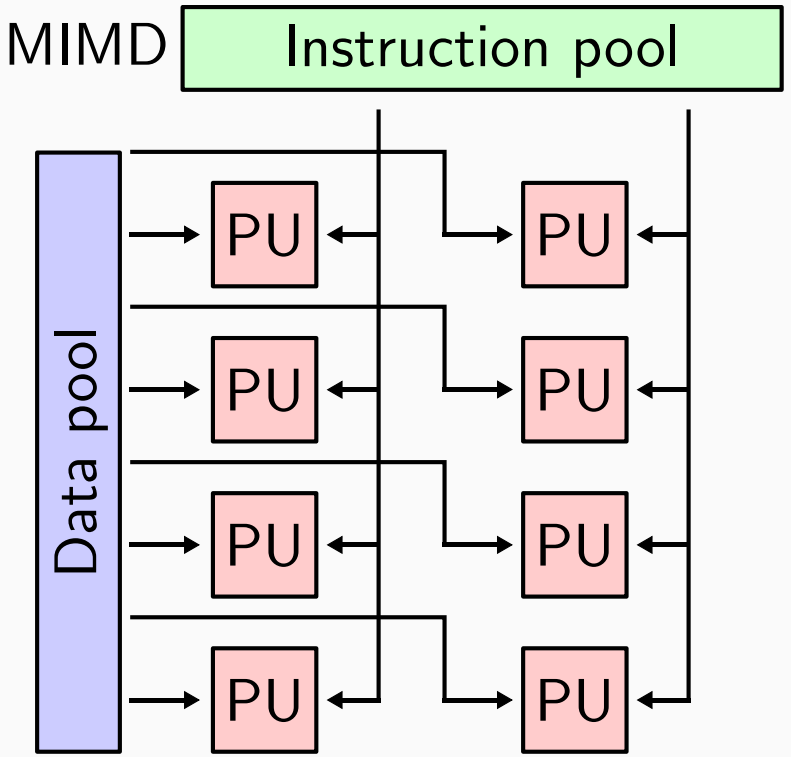

Multiple Instruction, Multiple Data

MISD

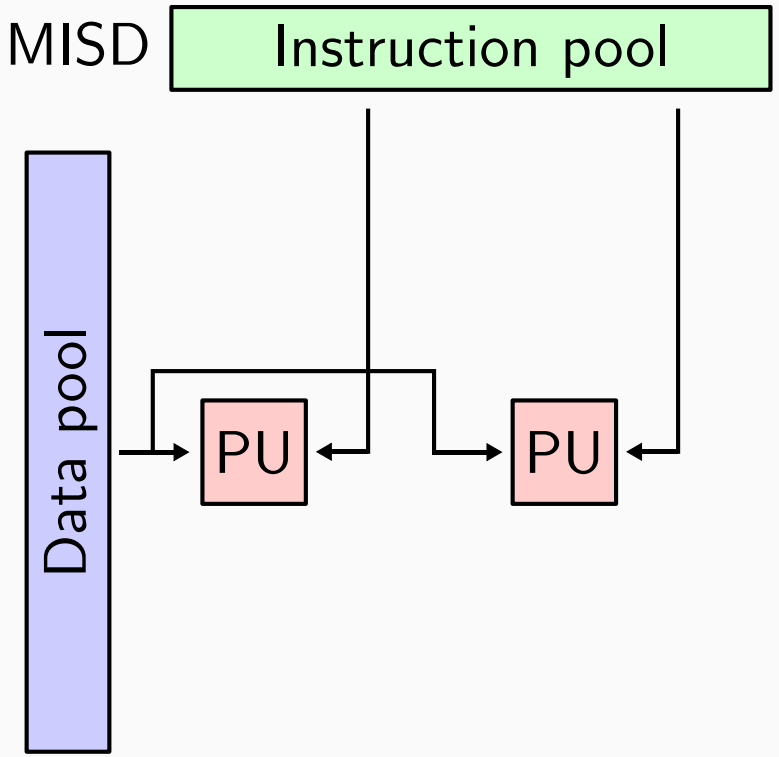

Multiple Instruction, Single Data

Links zu Flynn

- Some Computer Organizations and Their Effectiveness: Paper von Flynn (1972)
- Validating UTF-8 In Less Than One Instruction Per Byte: SIMD-Anwendungsbeispiel

Daten- und Taskparallelismus

Parallele Probleme sind üblicherweise entweder

- „datenparallel“: Problem kann auf identische Ausführungseinheiten verteilt werden
  Beispiel: `map primeFactors [1432793, 651433, ...]`
- „taskparallel“: Problembestandteile sind nicht homogen
  Beispiel: Videospiel mit Render-, Netzwerk- und Logikprozessen

Datenparallele Probleme sind i.d.R. einfacher zu behandeln (auch: „embarrassingly parallel“). Bei manchen Problemen verschwimmt die Grenze auch (bspw. Webserver).

MPI-Basics

MPI

MPI („Message Passing Interface“) ist ein Standard für Parallelprogrammierung. Es existieren verschiedene Implementierungen für verschiedene Sprachen. Die VL verwendet Open MPI, eine Open-Source-Implementierung.

- MPI-„Prozesse“ beziehen sich i.d.R. auf Prozessorkerne
- Message Passing statt Shared Memory:
  - Daten werden explizit über `Send` und `Recv` geteilt
- MPI-Prozesse werden in sog. *Communicators* eingeteilt. Wir verwenden immer den Communicator, der alle Prozesse enthält (`MPI_COMM_WORLD`)

Installation von MPI

MPI-Beispiele gehen von Linux-Systemen aus, verwendet unter Windows bitte WSL.

- `apt install openmpi-bin` (Ubuntu)
- `pacman -S openmpi` (Arch Linux)
- `dnf install openmpi` (Fedora)
- `brew install open-mpi` (macOS)

Verwendet `mpicc --version` zum Testen der Installation.

MPI: Grundgerüst

```
#include <mpi.h>

int main(int argc, char** args) {
  int size, rank;

  MPI_Init(&argc, &args);
  MPI_Comm_size(MPI_COMM_WORLD, &size);
  MPI_Comm_rank(MPI_COMM_WORLD, &rank);

  ...

  MPI_Finalize();
}
```

MPI: Grundgerüst

Grundlegende Begriffe:

- *Communicator*: Gruppe von Prozessen
- `MPI_COMM_WORLD`: Communicator, der alle Prozesse enthält
- `size`: Gesamtzahl der Prozesse
- `rank`: Laufende Nummer eines Prozesses $\in [0, \texttt{size})$
- `root`: Ausgangspunkt einer kollektiven Operation

Bauen und Ausführen von MPI-Programmen

MPI-Programme werden mit `mpicc` (Wrapper um `gcc` oder `clang`) kompiliert:

```
cd demos/mpi/hello
mpicc -o hello hello.c # oder make
```

Um ein Programm auszuführen, wird `mpirun` verwendet:

```
mpirun --host localhost:N ./hello
```

- `N` ist die Zahl der Prozesse, die ausgeführt werden sollen
- Betrachtet die Demos `mpi/hello` und `mpi/sendrecv`.

Beispielausführung von `mpi/hello`

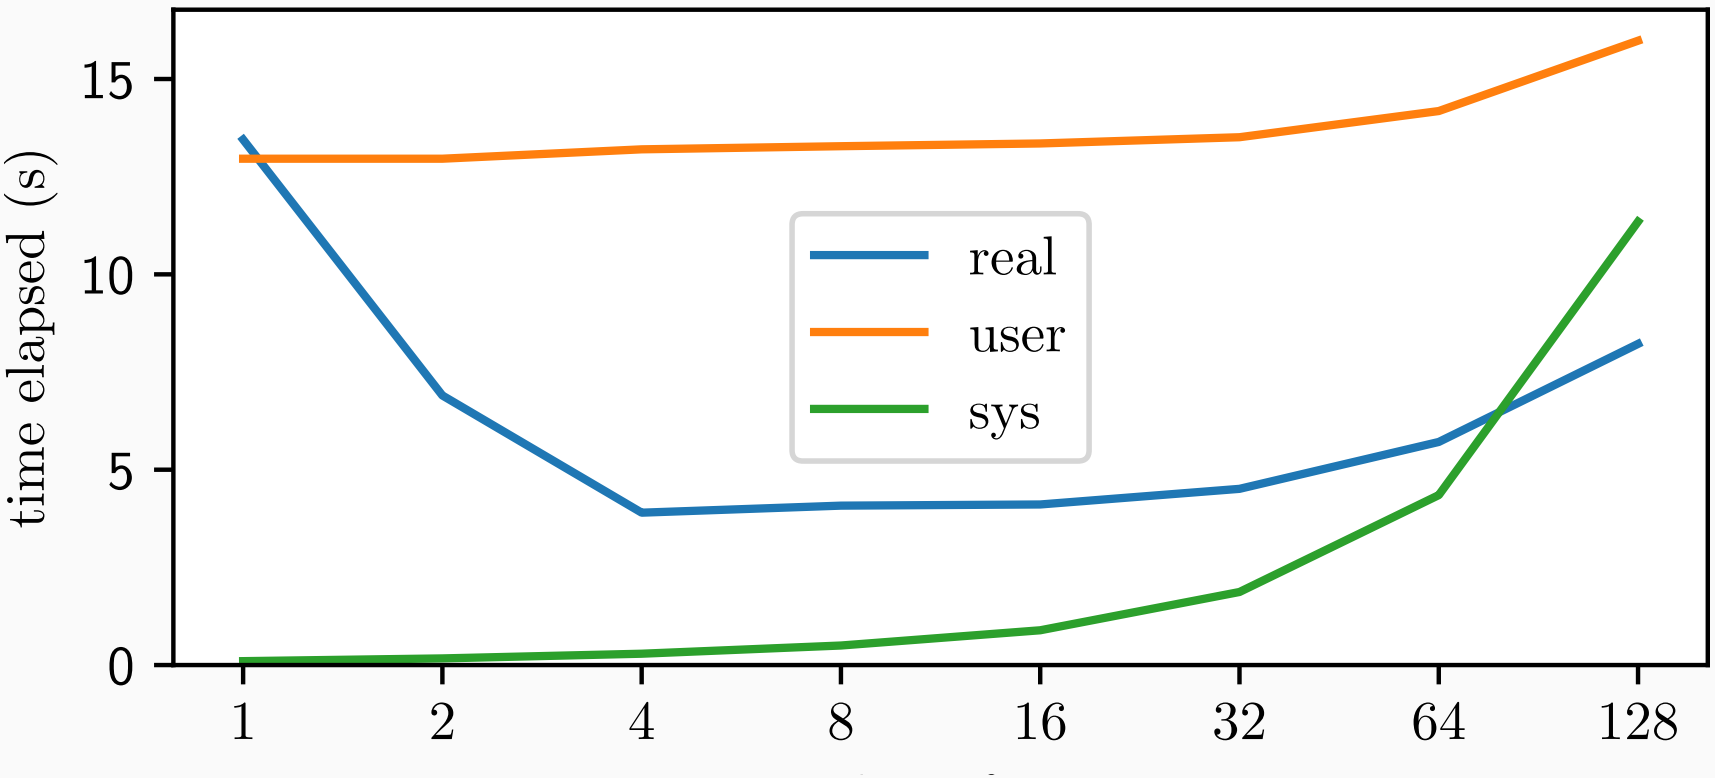

- *real*: Tatsächlich vergangene Zeit
- *user*/*sys*: Auf Prozessoren vergangene Zeit (Im User- bzw. Kernelmode)

Beispielausführung von `mpi/hello`

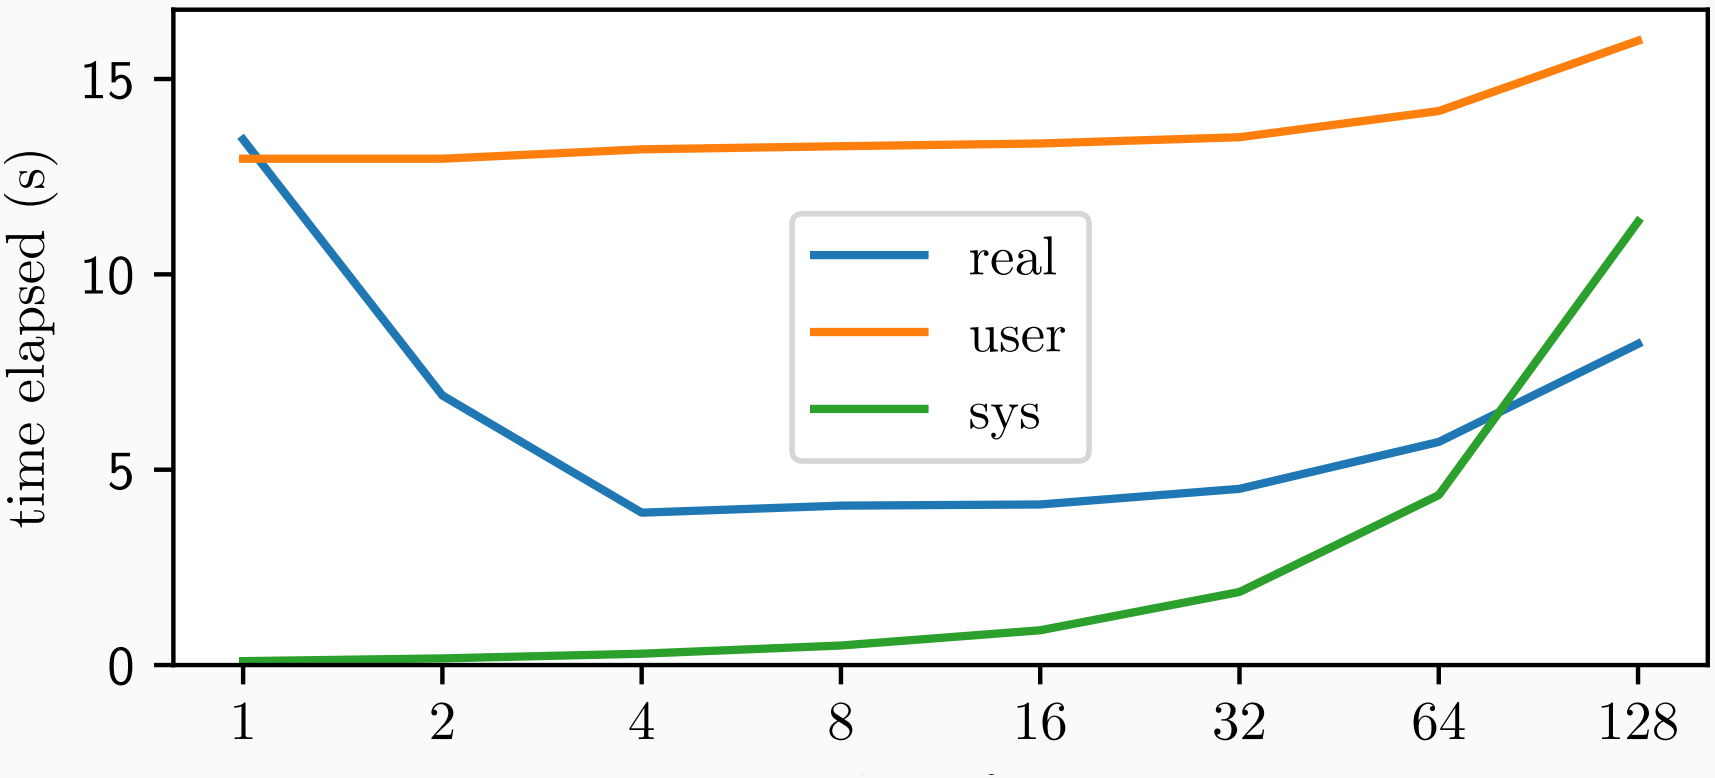

- *real*: Tatsächlich vergangene Zeit
- *user*/*sys*: Auf Prozessoren vergangene Zeit (Im User- bzw. Kernelmode)
- Prozessor: 4 × Intel Core i5-7600K @ 3,8GHz

Send/Recv

Mit den Message-Passing-Primitiven `Send` und `Recv` werden Daten zwischen Prozessen ausgetauscht.
Die Aufrufe sind unabhängig vom Medium (IPC, Sockets, ...).

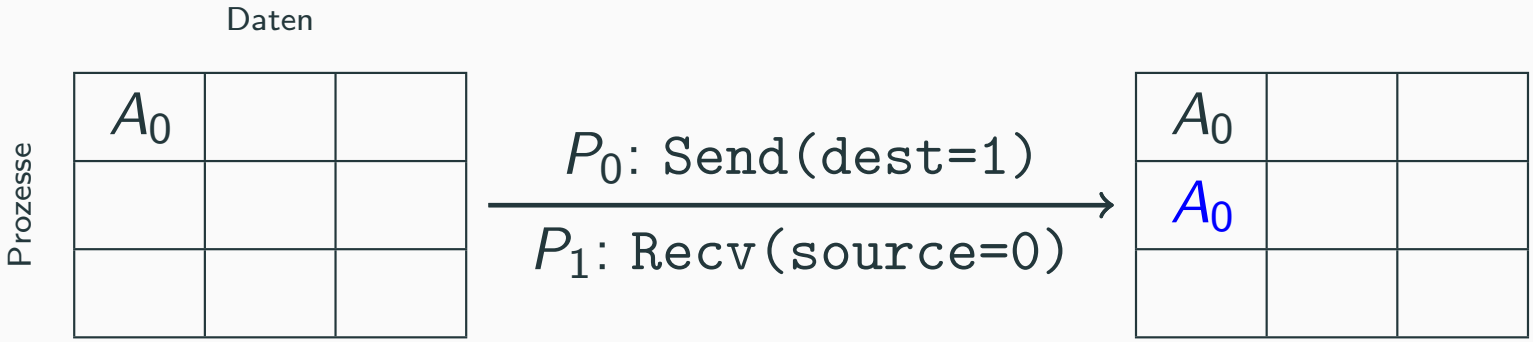

- `int MPI_Send(buf, count, datatype, dest, tag, comm)`
- `int MPI_Recv(buf, count, datatype, source, tag, comm, status)`

Kollektive Operationen

Bcast

`Bcast` verteilt ein Datum auf alle Prozesse.

- `int MPI_Bcast(buf, count, datatype, root, comm)`
- Daten befinden sich ursprünglich auf `root`
  - $\rightsquigarrow$ Fallunterscheidung in `Bcast`:
  - `if rank == root then forall others: send() else recv()`

Bcast

`Bcast` verteilt ein Datum auf alle Prozesse.

- `int MPI_Bcast(buf, count, datatype, root, comm)`
- Daten befinden sich ursprünglich auf `root`
  - $\rightsquigarrow$ Fallunterscheidung in `Bcast`:
  - `if rank == root then forall others: send() else recv()`

Implementiert `custom_Bcast` in `demos/mpi/custom_broadcast`!

Scatter

`Scatter` verteilt eine Liste von Daten auf mehrere Prozesse.

- `int MPI_Scatter(sendbuf, sendcount, sendtype, recvbuf, recvcount, recvtype, root, comm)`
- `sendcount`, `recvcount`: Zahl der Elemente, die an einen Prozess verteilt werden
- I.d.R.: `sendcount == recvcount`

Gather

`Gather` sammelt Daten von allen Prozessen in einer Liste.

- `int MPI_Gather(sendbuf, sendcount, sendtype, recvbuf, recvcount, recvtype, root, comm)`
- `sendcount`, `recvcount`: Zahl der Elemente, die an einen Prozess verteilt werden
- I.d.R.: `sendcount == recvcount`

Scatter und Gather

Scatter und Gather sind mehr oder weniger „invers“:

```
int nums[4];
int local;
if (rank == 0) { nums = {0, 1, 2, 3}; }

MPI_Scatter(nums, 1, MPI_INT, &local, 1, MPI_INT,
    0, MPI_COMM_WORLD);
// in P_i gilt: local = i
MPI_Gather(&local, 1, MPI_INT, nums, 1, MPI_INT,
    0, MPI_COMM_WORLD);
```

Häufiges Muster: Scatter, Daten bearbeiten, Gather, Ergebnisse zusammenführen

Aufgabe zu Scatter und Gather

Implementiert folgendes Programm mit MPI:

- N: Prozessoranzahl (`MPI_Comm_size`), $x = 1000$
- P_0 legt `long`-Liste mit Elementen $[1, 2, ..., N \cdot x]$ an
- P_i summiert einen x-Ausschnitt der Liste mit $i \in [0; N)$
- P_0 summiert die einzelnen Summen

Verwendet dafür:

- `MPI_Comm_size`, `MPI_Comm_rank`
- `MPI_Scatter`
- `MPI_Gather`

Dokumentation für MPI-Funktionen bekommt ihr mit `man <f>`

Allgather

`Allgather` ist die „Verkettung“ von `Gather` und `Bcast`.

- `int MPI_Allgather(sendbuf, sendcount, sendtype, recvbuf, recvcount, recvtype, comm)`
- Im Gegensatz zu `Gather` gibt es keinen Parameter `root`

Alltoall

`Alltoall` stückelt Daten von jedem Prozess und verteilt sie.

- `int MPI_Alltoall(sendbuf, sendcount, sendtype, recvbuf, recvcount, recvtype, comm)`
- Es führt sozusagen jeder Prozess einmal `Scatter` aus

Reduce

`Reduce` wendet eine assoziative Operation auf verteilte Daten an.

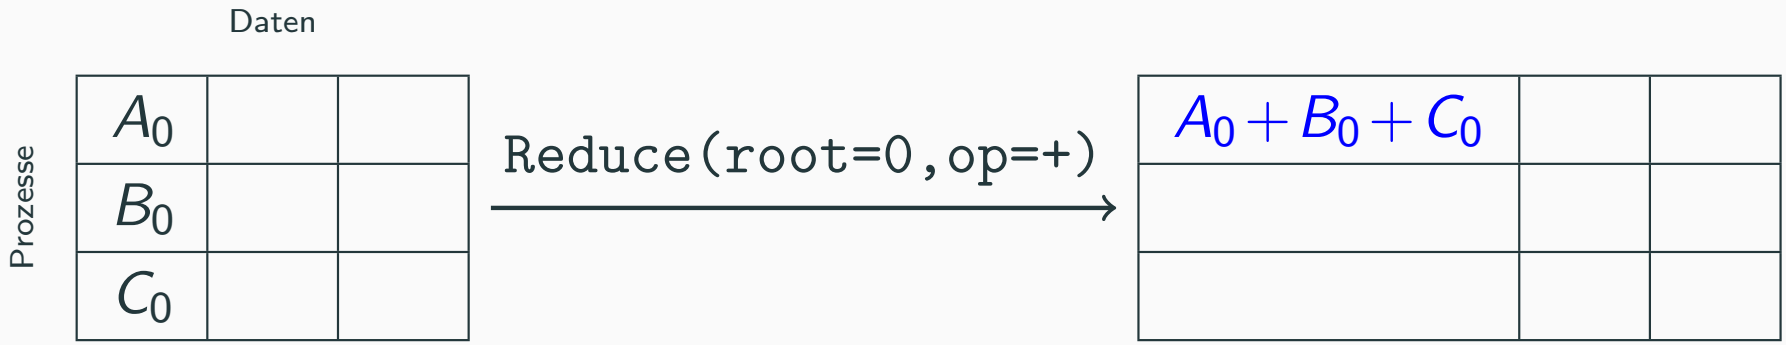

- `int MPI_Reduce(sendbuf, recvbuf, count, type, op, root, comm)`
  - Beispiele für op: `MPI_SUM`, `MPI_PROD`, `MPI_MIN`, `MPI_MAX`, etc.
- *Ungefähr* dasselbe wie ein Fold!

Reduce

`Reduce` wendet eine assoziative Operation auf verteilte Daten an.

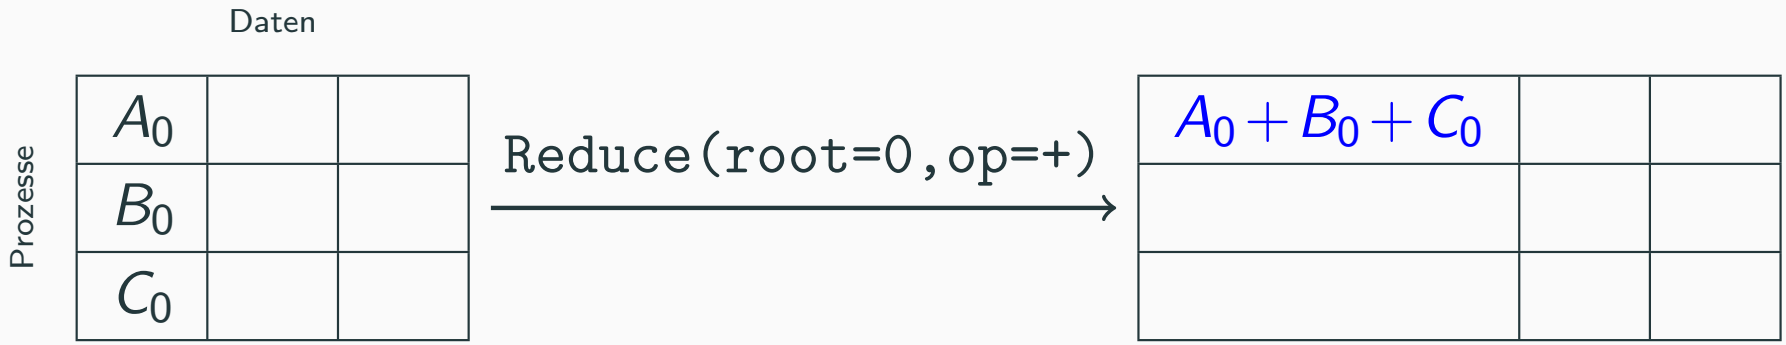

- `int MPI_Reduce(sendbuf, recvbuf, count, type, op, root, comm)`
  - Beispiele für op: `MPI_SUM`, `MPI_PROD`, `MPI_MIN`, `MPI_MAX`, etc.
- *Ungefähr* dasselbe wie ein Fold!
- Ersetzt den letzten Teil der Summenaufgabe durch einen Aufruf zu `Reduce`!

Allreduce

`Allreduce` ist die Verkettung von `Reduce` und `Bcast`.

- `int MPI_Allreduce(sendbuf, recvbuf, count, type, comm, op, comm)`
- Wie bei `Allgather`/`Alltoall`: Kein `root`-Parameter
- `Reduce` und `Allreduce` funktionieren außerdem auch „mehrspaltig“, d.h. auch $A_1 + B_1 + C_1$ etc.

Ende

Ende

- Im CAS könnt ihr euch bis zum 24.03. für die PP-Klausur anmelden
  - Termin: 31.03.2023
- Bis zum 15.02. könnt ihr euch Rückmelden
- Noch eine gute Woche :)